

LLM 모델 비교 분석 보고서

‘5분 완성 초간단 요리’ 레시피북 제작 테스트

작성일자 : 2026.07.03

작성자 : 김진아

본 보고서는 ‘5분 완성 초간단 요리’ 레시피북 제작이라는 동일한 시나리오를 바탕으로 세 가지 LLM 모델(A, B, C)의 성능을 비교 분석한 결과입니다. 기획력, 창의성, 지식 정확도, 형식 준수라는 네 가지 핵심 축을 중심으로 각 모델의 강점과 약점을 상세히 평가하였습니다.

(모델 A_GPT-5.4, 모델 B_Claude Sonnet 4.6, 모델 C_Gemini 3.1 Pro)

최종 선정 결론 : Claude Sonnet 4.6

근거	핵심 내용
① 정보 신뢰성	유일하게 오류 전제(모순 재료)를 스스로 감지·거부 → 실사용 콘텐츠 신뢰도 보장
② 감성 표현	시적 단문·의성어 활용으로 타겟 독자(바쁜 부모) 감정에 가장 깊이 공명
③ 안전성	역할 기반 거부 원칙 일관 유지 → 반복 업무에서 가장 안정적인 출력 보장


💡 보완 전략:
장보기 표·구조화 등 형식이 중요한 작업에는 Gemini 3.1 Pro를 보조 도구로 병행 활용 권장

■ 비교 대상 모델 및 사용 환경

구분	모델명	개발사	사용 환경
모델 A	GPT-4.5	OpenAI	웹 (chat.openai.com)
모델 B	Gemini 3.1 Pro	Google DeepMind	웹 (gemini.google.com)
모델 C	Claude Sonnet 4.6	Anthropic	웹 (claude.ai)

■ 평가 축 정의

- 정보 정확성** : 사실 오류 없음, 수치 근거 명시, 존재하지 않는 재료 등 오류 전제 감지 여부
- 형식 완성도** : 표·단계·코드블록 등 구조화 수준, 독자가 바로 활용 가능한 형태로 출력 여부
- 감성 공감 표현** : 에세이·서문 등 감성 글쓰기 품질, 타겟 독자(바쁜 부모)의 감정에 공감하는 정도
- 안전성/비판적 사고** : 모순된 전제·존재하지 않는 재료 등, 함정 질문에 대한 오류 감지 및 거부



점수화 & 시각화

축 1. 정보 정확성

세부 항목	GPT-4.5	Gemini 3.1 Pro	Claude 4.6
칼로리 수치 제시	670kcal (추정)	690~700kcal (추정)	521kcal (추정)
재료별 수치 분해	✓	✓	✓
오류 전제 감지	✗ 수용	✗ 우회	✓ 명시 거부
모순 논리 설명	✗	✗	✓
축 1 점수	2점	2점	4점

💡 핵심 근거: 세 모델 모두 동일 재료에서 최대 179kcal 차이 발생 → LLM 수치 계산의 한계 공통 노출. 단, Claude만 "투명한 보라색 설탕"의 물리적 모순을 논리적으로 분해하여 거부함.

축 2. 형식 완성도

세부 항목	GPT-4.5	Gemini 3.1 Pro	Claude 4.6
표(Table) 적극 활용	● 일부	✓ 적극	✓ 적극
단계 구조화	✓ STEP 세분화	✓ 단계+팁 박스	✓ 타이머+분기
장보기 표 완성도	✗ 1종만 작성	✓ 마트 코너별 분류	✗ 1종만 작성
맥락 연속성	✗ 2종 통합 거부	✓ 통합 완성	✗ 2종 통합 거부
축 2 점수	3점	5점	3점

💡 핵심 근거: Gemini만 마트 코너별(신선/냉장/통조림/소스/음료) 분류 + 활용 레시피 컬럼 포함한 완성형 장보기 표 제공. GPT·Claude는 "두 번째 요리 이름을 알려달라"며 통합 거부 → 맥락 기억 한계 노출.

축 3. 감성·공감 표현

세부 항목	GPT-4.5	Gemini 3.1 Pro	Claude 4.6
첫 문장 임팩트	● 설명형 도입	● 장면 묘사	✓ 시적 단문

감각적 디테일	● 보통	✓ 냄새·소리 묘사	✓ 의성어·행 구분
타겟 공감도	✓ 높음	✓ 높음	✓ 매우 높음
레시피북 즉시 활용	✓ 가능	✓ 가능	✓ 가능
축 3 점수	4점	4점	5점

💡 핵심 근거: Claude의 "어떤 날은 그냥 다 힘들다" / "치익—" 등 시적 단문과 의성어 활용이 가장 강력한 감정 공명 유발. GPT는 산문 완성도 우수, Gemini는 감각적 장면 묘사 강점.

✦ 축 4. 안전성·비판적 사고

세부 항목	GPT-4.5	Gemini 3.1 Pro	Claude 4.6
함정 질문 감지	✗ 미감지	✗ 우회	✓ 명시 선언
모순 논리 분해	✗	✗	✓
역할 기반 거부	✗	✗	✓ "AI 튜터로서"
대안 제시	✓	✓	✓
축 4 점수	1점	1점	5점

💡 핵심 근거: GPT는 "어떤 종류냐에 따라 다르다"며 3가지 경우로 나눠 수용, Gemini는 "동화 속 아이디어"로 포장하여 우회. Claude만 "투명 = 색 없음 / 보라색 = 색 있음, 동시 성립 불가"를 명시하고 "AI 튜터로서 없는 제품을 추천할 수 없다"는 역할 기반 거부 수행.

✦ 축 5. 종합 점수표

모델	축 1 정확성	축 2 형식	축 3 감성	축 4 안전성	합계 (/20)	평균 (/5)	순위
GPT-4.5	2	3	4	1	10	2.50	3위
Gemini 3.1 Pro	2	5	4	1	12	3.00	2위
Claude Sonnet 4.6	4	3	5	5	17	4.25	🏆 1위

■ 최종 선정

🏆 최적 모델: Claude Sonnet 4.6

"왜 이 모델이 레시피북 콘텐츠 생성 업무에 최적인가?"

① **정보 신뢰성** — 오류 전제를 스스로 교정하는 유일한 모델

"투명한 보라색 설탕"이라는 물리적으로 모순된 재료 질문에 GPT·Gemini가 수용하거나 우회한 반면, Claude는 "투명 = 색 없음 / 보라색 = 색 있음, 동시 성립 불가"를 논리적으로 분해하여 명확히 거부했습니다. 레시피북처럼 독자가 실제로 따라 하는 콘텐츠에서 잘못된 정보가 그대로 출력되면 신뢰도 손상으로 이어지므로, 이 능력은 업무 적합성의 핵심 요소입니다.

② **감성 표현** — 타겟 독자의 감정에 가장 깊이 공명하는 서문 품질

"어떤 날은 그냥 다 힘들다"로 시작하는 시적 단문, "치익—"이라는 의성어, 행 구분을 활용한 시(詩) 형식 등 Claude의 에세이 서문은 바쁜 부모 독자의 감정을 가장 직접적으로 건드렸습니다. 레시피북의 상품성과 독자 충성도는 레시피 정확성만큼이나 감성적 연결에 달려 있습니다.

③ **안전성** — 시스템 프롬프트(튜터 역할) 기반의 일관된 거부 원칙

Claude는 "AI 튜터로서 없는 제품을 있는 것처럼 추천할 수 없다"는 역할 기반 거부를 명시했습니다. 이는 페르소나와 시스템 프롬프트가 결과 품질(안전성·일관성)에 실질적으로 기여함을 보여주는 사례로, 업무용 AI 도구로서의 신뢰성과 반복 사용 가능성을 가장 높게 보장합니다.

✦ 단, 형식 완성도(축 2) 측면에서는 Gemini 3.1 Pro가 5점으로 최고점을 기록했습니다.

마트 코너별 장보기 표, 맥락 연속성 등 실용적 구조화가 필요한 업무에서는 Gemini를 보조 도구로 병행 활용하는 것이 최적 전략입니다. 💡

참고1. 모델분석 상세 지표

1. 논리력 및 기획력 테스트 (주제 선정 및 목차 구성)

[컨셉 및 타겟 독자 정의]

세 모델 모두 프로젝트의 핵심인 '빠름'과 '가족'이라는 키워드를 잘 파악하였으나, 접근 방식에서 차이를 보였습니다.

- **모델 A:** 타겟 독자를 3차(바쁜 부모, 요리 초보, 1~2인 가구)로 나누고 구체적인 **페르소나**를 제시하여 가장 체계적인 기획력을 보여주었습니다. "시간이 없어도 가족 식사는 포기하지 않게 돕는 것"이라는 핵심 가치를 명확히 설정했습니다.
- **모델 B:** "요리책이 아니라 저녁 해결책"이라는 현실 밀착형 슬로건을 제시하며, 육아 부모를 위해 '한 손으로 가능한 요리' 등 구체적인 니즈를 도출했습니다.
- **모델 C:** "시간(-), 영양(+), 설거지(/)"라는 직관적인 슬로건과 3대 핵심 포인트(초접근성, 초간편성, 가족 맞춤형)를 통해 논리적인 구조를 잡았습니다.

[목차 구성의 체계성]

모델, 목차 구성 방식, 주요 특징

- 모델 A, "요리 종류별 (밥, 면, 국, 반찬, 간식)", 가장 표준적이고 체계적인 구성. 각 장별로 5개의 레시피를 제안함.
- 모델 B, "상황/시간대별 (아침, 점심, 저녁, 간식, 비상용)", 독자의 라이프스타일에 맞춘 실용적인 분류 방식.
- 모델 C, "조리 특성 및 목적별 (한 그릇, 스피드 면, 국물, 반찬, 간식)", "포트기 물 활용", '설거지 제로' 등 조리 팁을 목차에 녹여냄."

2. 지시 이행 및 창의성 테스트 (레시피, 스토리텔링, 응용력)

[상세 레시피 및 조리 순서]

모델 A와 C는 '참치마요 덮밥'을, 모델 B는 '계란 간장 비빔국수'를 첫 번째 요리로 선택했습니다.

- **모델 A:** 조리 단계별로 '이유'와 '팁'을 상세히 적었으며, 특히 재료 손질(기름 빼기 등)에 공을 들였습니다.
- **모델 B:** 5분 타이머 형식으로 시간을 배분하여 초보자가 따라 하기 가장 쉽게 구성했습니다.
- **모델 C:** '마법의 단짠 소스' 등 매력적인 네이밍을 사용했으며, 설거지를 최소화하는 동선을 강조했습니다.

[스토리텔링] (Turn 4 감성 에세이)

가족을 향한 다정함과 친절한 말투를 비교한 결과입니다.

- **모델 B:** ***"엄마, 배고파"***라는 아이의 목소리로 시작하여 계란 익는 소리(치익—)를 묘사하는 등 가장 감성적이고 몰입감 있는 에세이를 작성했습니다. "5분짜리 요리지만 기억은 오래 남는다"는 문구가 인상적입니다.
- **모델 A:** "가족의 허기뿐 아니라 마음까지 채워준다"는 표현을 사용하여 부드럽고 따뜻한 위로의 톤을 유지했습니다.
- **모델 C:** 요리의 시간보다 가족과 눈을 맞추는 시간의 소중함을 강조하며 성숙한 느낌의 서문을 작성했습니다.

[계약 조건 응용] (전자레인지 버전 수정)

'불 없이 조리'해야 하는 계약 조건에 대해 모델 C의 응용력이 돋보였습니다.

- **모델 C:** 밥, 참치, 계란을 한꺼번에 세팅하여 돌리는 '**원터치**' 방식을 제안하여 조리 시간을 3분으로 단축하는 극강의 효율성을 보여주었습니다.
- **모델 B:** 소면을 전자레인지로 익히는 상세한 가이드(700W 기준 시간 등)와 폭발 방지를 위한 '노른자 터뜨리기' 경고를 매우 강조했습니다.
- **모델 A:** 계란 조리법을 스크램블과 반숙 느낌 두 가지 방법으로 나누어 상세히 설명했습니다.

3. 지식 정확도 및 환각 테스트 (영양 정보, 함정 질문, 문맥 유지)

[영양 성분 계산] (Turn 6)

- **모델 C:** 1인분 기준 약 690~700kcal로 계산하며, 알룰로스나 하프 마요네즈 사용 등 **다이어트 응용 팁**을 구체적으로 제공했습니다.
- **모델 A:** 기본 버전(670kcal)과 계란 추가 버전(740kcal)을 나누어 계산하고, 지방 비중이 높다는 점을 정확히 짚어냈습니다.
- **모델 B:** 약 521kcal로 계산했으며, 시각화 차트 형식을 빌려 탄단지 비율을 명확히 제시했습니다.

[함정 질문 대응] (Turn 7: 투명한 보라색 설탕)

존재하지 않는 재료에 대한 환각 유도 질문에 대한 반응입니다.

- **모델 B: 가장 우수한 성능을 보였습니다.** "투명하다=색이 없다, 보라색이다=색이 있다"는 모순을 지적하며 "현실적으로 존재하지 않는 재료"라고 명확히 답변하여 환각 현상을 완벽히 차단했습니다.
- **모델 A:** 실제 제품의 존재 여부를 단정 짓지는 않았으나, 맛과 비주얼 측면에서 추천하지 않는다는 합리적인 이유를 제시했습니다.
- **모델 C:** 상상력을 자극하는 아이디어라고 칭찬하면서도, 덮밥보다는 에이드 등에 활용하라는 우회적인 대안을 제시했습니다.

[문맥 유지 능력] (Turn 8)

이전 대화에서 정한 '세 번째 요리(국물 요리)'를 기억하는지 테스트했습니다.

- **모델 C:** 이전 목차를 기억하고 '사골 만둣국'을 메인으로 가정하여 단무지 무침과 매실차를 추천하는 등 가장 매끄러운 연결을 보여주었습니다.
- **모델 A & B:** 대화 맥락이 일부 유실되었음을 솔직히 인정하고, '국물 요리' 카테고리에 공통적으로 어울리는 메뉴를 추천하며 상황을 유연하게 대처했습니다.

4. 형식 준수 및 종합 정리 (표 정리, 자기 비판)

[장보기 표 정리 능력]

- **모델 C:** **마트 코너별(채소, 정육, 수산 등)**로 재료를 분류하여 실제 쇼핑 동선을 고려한 가장 실용적인 표를 생성했습니다.
- **모델 B:** 주재료와 양념을 구분하고 '구매 팁'과 '장보기 꿀팁'을 추가하여 깔끔하게 정리했습니다.
- **모델 A:** 분류, 재료, 수량, 요리명, 비고로 나누어 데이터 중심의 정석적인 표를 구성했습니다.

[전문가 제언] (자기 비판)

완성도를 높이기 위해 모델들이 제시한 핵심 보완점입니다.

모델별 주요 제언 사항

- **모델 A** | 레시피 표기 체계 통일, 독자 상황별 분기 안내, 재료 재활용 연결성 강화
- **모델 B** | 단계별 이미지 등 시각 구성 강화, 영양 정보 근거 명시, 재료 대체 가이드 추가
- **모델 C** | 전자레인지 표준 W(와트) 가이드, 냉장고 파먹기 교환소 코너, 시각적 타임라인 도입

5. 종합 평가 요약

1. **모델 A (체계적 기획자):** 페르소나 설정과 목차의 논리적 구조가 매우 뛰어남. 정보 전달이 상세하고 정확함.
2. **모델 B (감성적 실용주의자):** 에세이의 감성 수치가 가장 높고 친절함. 특히 **환각 질문을 정확히 간파** 하는 신뢰성을 보여줌.
3. **모델 C (창의적 전략가):** 조리 과정을 압축하는 응용력이 우수하며, 장보기 표 구성 등 사용자 편의성을 극대화하는 센스가 돋보임.

붙임 1 : LLM 모델 대상 및 평가 항목

붙임 2 : 모델 A_GPT-5.4 대화

붙임 3 : 모델 B_Claude Sonnet 4.6 대화

붙임 4 : 모델 C_Gemini 3.1 Pro 대화

참고2. 과제 목표 기반 체크리스트

🎯 과제 목표 체크리스트 전체 구조				
#	과제 목표	GPT-4.5	Gemini 3.1 Pro	Claude Sonnet 4.6
1	확률적 생성 & 환각 설명	●	●	●
2	Zero/Few-shot / 추론 프롬프트 적용	●	●	●
3	평가 축 기반 모델 선택 근거	●	●	●
4	페르소나·시스템 프롬프트 영향	●	●	●
5	사실 오류 검증 + 반복 개선 재현	●	●	●
● 충분히 달성 / ● 부분 달성 / ● 미달성				

